

**ITERA**

**Modul 3 Praktikum  
Statistika Sains Data**

**Regresi Logistic**

**Program Studi Sains Data  
Fakultas Sains  
Institut Teknologi Sumatera**


**2024**

## A. Tujuan Praktikum

1. Mahasiswa mampu menaksir model regresi logistic menggunakan software RStudio.
2. Mahasiswa mampu menentukan kualitas dari model regresi logistic yang terbentuk.

## B. Teori Dasar

Regresi logistik dalam [Pemrograman R](#) adalah algoritma klasifikasi yang digunakan untuk mencari kemungkinan keberhasilan suatu peristiwa dan kegagalan suatu peristiwa. Regresi logistik digunakan jika variabel terikatnya bersifat biner (0/1, Benar/Salah, Ya/Tidak). Fungsi logit digunakan sebagai fungsi link dalam distribusi binomial. Probabilitas variabel hasil biner dapat diprediksi menggunakan teknik pemodelan statistik yang dikenal sebagai regresi logistik. Ini banyak digunakan di berbagai industri, termasuk pemasaran, keuangan, ilmu sosial, dan penelitian medis. Fungsi logistik, biasa disebut fungsi sigmoid, merupakan ide dasar yang mendasari regresi logistik. Fungsi sigmoid ini digunakan dalam regresi logistik untuk menggambarkan korelasi antara variabel prediktor dan kemungkinan hasil biner.



Regresi logistik juga dikenal sebagai regresi logistik binomial. Hal ini didasarkan pada fungsi sigmoid di mana keluaran adalah probabilitas dan masukan dapat berkisar dari  $-\infty$  hingga  $+\infty$ .

Regresi logistik juga dikenal sebagai model linier umum. Karena digunakan sebagai teknik klasifikasi untuk memprediksi respons kualitatif, Nilai  $y$  berkisar antara 0 hingga 1 dan dapat direpresentasikan dengan persamaan berikut:

$$\text{Odds} = \frac{P}{1 - P}$$

p adalah probabilitas karakteristik yang diinginkan. Rasio odds didefinisikan sebagai probabilitas keberhasilan dibandingkan dengan probabilitas kegagalan. Ini adalah representasi utama dari koefisien regresi logistik dan dapat mengambil nilai antara 0 dan tak terhingga. Rasio odds 1 adalah ketika probabilitas keberhasilan sama dengan probabilitas kegagalan. Rasio odds 2 adalah ketika peluang sukses dua kali lipat peluang gagal. Rasio odds 0,5 adalah ketika peluang kegagalan dua kali lipat peluang sukses.

$$\log(\text{Odds}) = \log\left(\frac{P}{1 - P}\right)$$

Karena kita bekerja dengan distribusi binomial (variabel terikat), kita perlu memilih fungsi tautan yang paling cocok untuk distribusi ini.

$$\text{logit}(P) = \log\left(\frac{P}{1 - P}\right) = b_0 + b_1*1 + b_2*2 + b_3*3 + \dots + b_k*k$$

Ini adalah fungsi logit. Dalam persamaan di atas, tanda kurung dipilih untuk memaksimalkan kemungkinan mengamati nilai sampel daripada meminimalkan jumlah kesalahan kuadrat (seperti regresi biasa). Logit juga dikenal sebagai log peluang. Fungsi logit harus berhubungan linier dengan variabel bebas. Ini dari persamaan A, dimana ruas kirinya merupakan kombinasi linier dari x. Hal ini mirip dengan asumsi OLS bahwa y berhubungan linier dengan x. Variabel  $b_0$ ,  $b_1$ ,  $b_2$ ...dst tidak diketahui dan harus diperkirakan berdasarkan data pelatihan yang tersedia. Dalam model regresi logistik, mengalikan  $b_1$  dengan satu unit akan mengubah logit sebesar  $b_0$ . Perubahan P akibat perubahan satu satuan akan bergantung pada nilai yang dikalikan. Jika  $b_1$  positif maka P bertambah dan jika  $b_1$  negatif maka P berkurang.

## C. Latihan Praktikum

### Pendahuluan

#### C.1 Package

Berikut adalah packages yang akan digunakan dalam praktikum ini, yaitu :

<b>Nama Package</b>	<b>Kegunaan</b>
<code>broom</code>	untuk merapikan tampilan data
<code>caret</code>	akan digunakan beberapa fungsi untuk membentuk Confusion Matrix
<code>DataExplorer</code>	akan digunakan beberapa fungsi seperti <code>plot_bar</code> , <code>plot_histogram</code> , <code>plot_boxplot</code> , untuk membantu visualisasi data
<code>grid</code>	diperlukan agar user defined function <code>arrange</code> bisa digunakan
<code>ISLR</code>	Sumber Datasets <code>default</code>
<code>pscl</code>	akan digunakan fungsi <code>pR2</code> (Pseudo $R^2$ ) untuk Evaluasi Model
<code>tidyverse</code>	

Untuk melakukan Instalasi, Anda bisa menggunakan syntax berikut ini :

```
install.packages(c("broom","caret","DataExplorer","grid","ISLR","pscl","tidyverse"))
```

Jangan lupa untuk load package tersebut.

```
library(broom)
library(caret)
library(DataExplorer)
library(grid)
library(InformationValue)
library(ISLR)
library(pscl)
library(tidyverse)
```

Sebenarnya Anda tidak perlu untuk load keseluruhan package, Anda bisa menggunakan syntax `namapackage::fungsi` untuk menggunakan suatu fungsi dari suatu package di R, selama package tersebut sudah Anda Install.

### C.1.2 Data

Data yang akan digunakan dalam praktikum ini ada 2, yaitu :

- Default Datasets yang berasal dari package ISLR
- Lending Club Datasets

### C.1.3 Tambahan

Untuk mempermudah visualisasi beberapa bagian dalam Praktikum ini, digunakan fungsi `arrange` yang dibuat oleh Stephen Turner

```
vp.layout <- function(x, y) viewport(layout.pos.row=x, layout.pos.col=y)

arrange <- function(..., nrow=NULL, ncol=NULL, as.table=FALSE) {

  dots <- list(...)

  n <- length(dots)

  if(is.null(nrow) & is.null(ncol)) { nrow = floor(n/2) ; ncol = ceiling(n/nrow)}

  if(is.null(nrow)) { nrow = ceiling(n/ncol)}

  if(is.null(ncol)) { ncol = ceiling(n/nrow)}

  ## NOTE see n2mfrow in grDevices for possible alternative

  grid.newpage()

  pushViewport(viewport(layout=grid.layout(nrow,ncol) ) )

  ii.p <- 1

  for(ii.row in seq(1, nrow)){

    ii.table.row <- ii.row
```

```

if(as.table) {ii.table.row <- nrow - ii.table.row + 1 }

for(ii.col in seq(1, ncol)){

  ii.table <- ii.p

  if(ii.p > n) break

  print(dots[[ii.table]], vp=vp.layout(ii.table.row, ii.col))

  ii.p <- ii.p + 1

}

}

}

```

## C.2 Default Datasets

### C.2.1 Eksplorasi Data

```
data(Default)
```

Untuk mengetahui lebih lanjut mengenai `Default`, Anda bisa menggunakan syntax berikut :

```
help(Default)
```

#### Deskripsi

*A simulated data set containing information on ten thousand customers. The aim here is to predict which customers will default on their credit card debt.*

#### Format

*A data frame with 10000 observations on the following 4 variables.*

- `default` : A factor with levels `No` and `Yes` indicating whether the customer defaulted on their debt
- `student` : A factor with levels `No` and `Yes` indicating whether the customer is a student
- `balance` : The average balance that the customer has remaining on their credit card after making their monthly payment
- `income` : Income of customer

## glimpse

Anda bisa melihatnya dengan `glimpse` dari `dplyr` yang merupakan bagian dari `tidyverse`

```
glimpse(Default)
```

```
## Rows: 10,000
## Columns: 4
## $ default <fct> No, No, No, No, No, No, No, No, No, No, No, No, No, No, No, ...
## $ student <fct> No, Yes, No, No, No, Yes, No, Yes, No, No, Yes, Yes, No, No, ...
## $ balance <dbl> 729.5265, 817.1804, 1073.5492, 529.2506, 785.6559, 919.5885...
## $ income <dbl> 44361.625, 12106.135, 31767.139, 35704.494, 38463.496, 7491...
```

## summary

Seandainya kita ingin mengetahui sebaran dan kecenderungan pola hubungan antar peubah, salah satu yang dapat dilakukan adalah sebagai berikut.


```
summary(Default)
```

```
## default      student      balance      income
## No :9667      No :7056      Min.   : 0.0      Min.   : 772
## Yes: 333      Yes:2944      1st Qu.: 481.7    1st Qu.:21340
##                                     Median : 823.6    Median :34553
##                                     Mean   : 835.4    Mean   :33517
##                                     3rd Qu.:1166.3    3rd Qu.:43808
##                                     Max.   :2654.3    Max.   :73554
```



## plot\_histogram

```
plot_histogram(Default)
```




`plot_histogram` ini menampilkan peubah dengan tipe numerik.

## plot\_bar

```
plot_bar(Default)
```






`plot_bar` ini menampilkan peubah dengan tipe kategorik.

### **plot\_boxplot**

Untuk melihat pola hubungan antara peubah numerik dan kategorik dapat lebih mudah diidentifikasi menggunakan `plot_boxplot`.

```
plot_boxplot(Default,by="default")
```




Output di atas memperlihatkan bahwa median pendapatan antara nasabah yang mengalami kredit macet atau tidak macet cenderung mirip. Sebaliknya, terdapat perbedaan jumlah tagihan kartu kredit pada nasabah dengan kredit macet dan yang tidak. Pada kasus ini, orang yang memiliki tagihan lebih banyak, cenderung lebih mengalami kredit macet.

#### student - balance

```
a1<-Default %>% filter(student=="Yes") %>%
  select(balance,default) %>%
  plot_boxplot(by="default", title="Default Occurrence on Student")
a2<-Default %>% filter(student=="No") %>%
  select(balance,default) %>%
```

```
plot_boxplot(by="default", title="Default Occurrence on Non-Student")
```

```
arrange(a1,a2)
```



```
## $page_1
```

```
##
```

```
## $page_1
```

**student - income**

```
b1<-Default %>% filter(student=="Yes") %>%
```

```
select(income,default) %>%
```

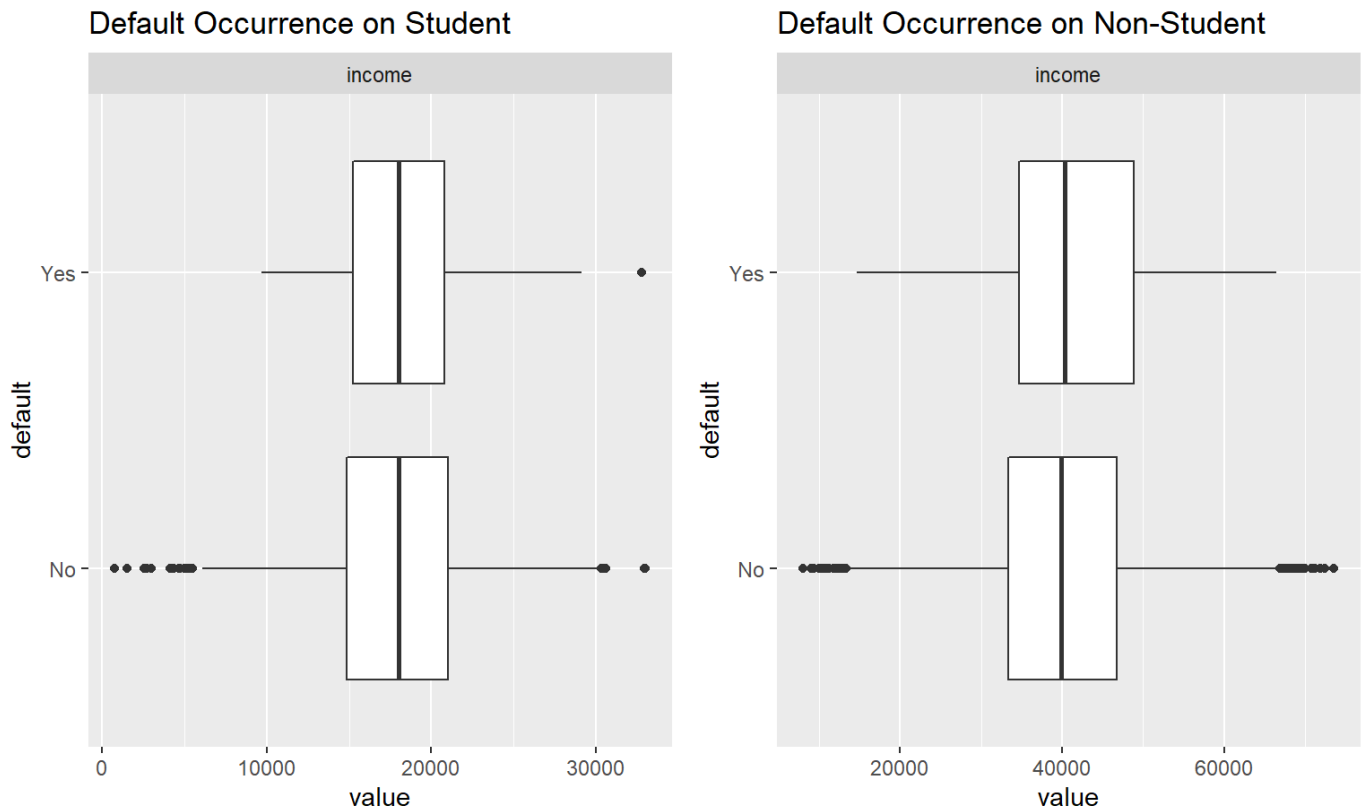
```
plot_boxplot(by="default", title="Default Occurrence on Student")
```

```
b2<-Default %>% filter(student=="No") %>%
```

```
select(income,default) %>%
```

```
plot_boxplot(by="default", title="Default Occurrence on Non-Student")
```

```
arrange(b1,b2)
```



```
## $page_1
```

```
##
```

```
## $page_1
```

### C.3 The Model, Estimation and Inference

Sebagai awal dari ilustrasi yang akan dibahas pada modul kali ini, akan diperlihatkan pemodelan regresi logistik dengan menggunakan satu peubah penjelas terlebih dulu.

```
reglog<-glm(default~balance,data=Default,family=binomial)
```

## summary (reglog)

```
##
## Call:
## glm(formula = default ~ balance, family = binomial, data = Default)
##
## Deviance Residuals:
##      Min       1Q   Median       3Q      Max
## -2.2697  -0.1465  -0.0589  -0.0221   3.7589
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept) -1.065e+01  3.612e-01  -29.49  <2e-16 ***
## balance      5.499e-03  2.204e-04   24.95  <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##      Null deviance: 2920.6  on 9999  degrees of freedom
## Residual deviance: 1596.5  on 9998  degrees of freedom
## AIC: 1600.5
##
## Number of Fisher Scoring iterations: 8
```

Default %>%

```
mutate(prob = ifelse(default == "Yes", 1, 0)) %>%
```

```
ggplot(aes(balance, prob)) +
```

```
geom_point(alpha = .15) +
```

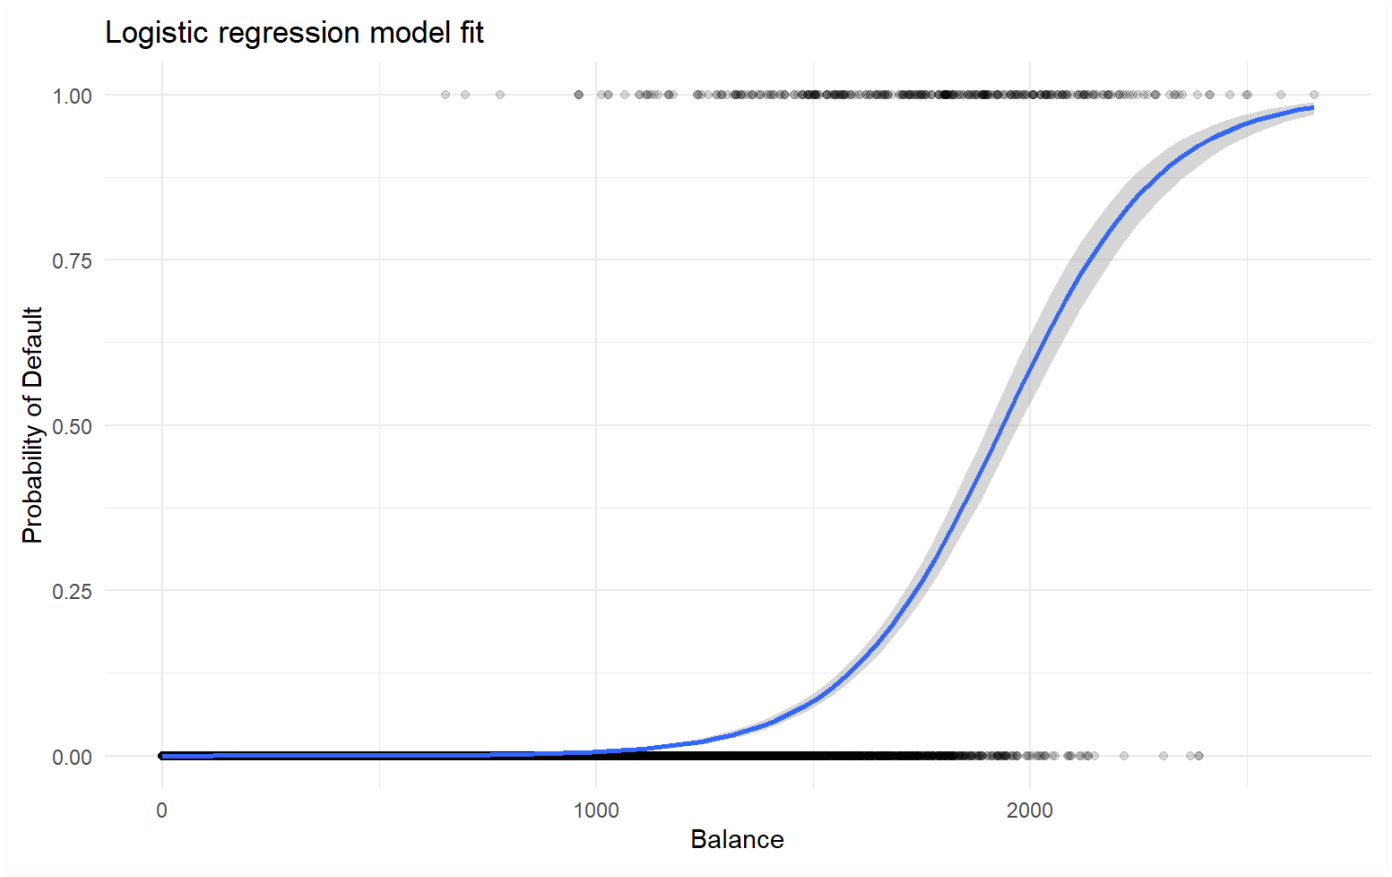
```
geom_smooth(formula=y~x, method = "glm", method.args = list(family = "binomial")) +
```

```
ggtitle("Logistic regression model fit") +
```

```
xlab("Balance") +
```

```
ylab("Probability of Default")+
```

```
theme_minimal()
```



### B.2.1 Interpreting coefficients

```
reglog$coefficients
```

```
## (Intercept)    balance
## 2.366933e-05 1.005514e+00
```

Seperti yang telah dibahas pada kelas perkuliahan,

hasil  $\beta_1=0.0055$  (positif) berarti membesarnya tagihan akan meningkatkan peluang gagal bayar. Pengguna kartu kredit yang lebih besar tagihannya memiliki risiko 0.0055 kali lebih besar untuk gagal bayar. Lebih tepat lagi, peningkatan satu unit tagihan (dollar) berhubungan dengan meningkatnya log-odds gagal bayar sebesar 0.0055 unit.

Untuk memudahkan interpretasi, seringkali digunakan rasio odds, yaitu rasio antara dua odds.

```
exp(reglog$coefficients)
```

```
##      (Intercept)      balance  
## -10.651330614    0.005498917
```

Pada ilustrasi ini, terlihat bahwa nilai rasio odds untuk peubah balance adalah 1.00551. Hal ini dapat diartikan bahwa ketika tagihan kartu kredit meningkat \$ 1 maka kemungkinan kejadian kredit macet meningkat sebesar 1.00551 kali dibandingkan tagihannya tetap

```
confint(reglog)
```

```
## Waiting for profiling to be done...
```

```
##           2.5 %      97.5 %  
## (Intercept) -11.383288936 -9.966565064  
## balance      0.005078926  0.005943365
```

### B.2.2 Prediction

Seandainya kita ingin memprediksi peluang kredit macet jika besarnya tagihan seorang nasabah adalah sebesar \$ 1,000

```
predict(reglog, newdata = data.frame(balance=1000), type="response")
```

```
##           1  
## 0.005752145
```

Artinya, seseorang yang memiliki jumlah tagihan \$ 1,000 diprediksi memiliki peluang kredit macet sebesar 0.005752145.

### B.2.3 Categorical Independent Variable



```
reglog2<-glm(default~student,data=Default,family=binomial)
```

```
summary(reglog2)
```

```
##
## Call:
## glm(formula = default ~ student, family = binomial, data = Default)
##
## Deviance Residuals:
##      Min       1Q   Median       3Q      Max
## -0.2970  -0.2970  -0.2434  -0.2434   2.6585
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept) -3.50413    0.07071  -49.55 < 2e-16 ***
## studentYes   0.40489    0.11502   3.52 0.000431 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##      Null deviance: 2920.6  on 9999  degrees of freedom
## Residual deviance: 2908.7  on 9998  degrees of freedom
## AIC: 2912.7
##
## Number of Fisher Scoring iterations: 6
```

```
predict(reglog2, newdata = data.frame(student="Yes"), type="res")
```

```
##           1
## 0.04313859
```

```
predict(reglog2, newdata = data.frame(student="No"), type="res")
```

```
##           1
## 0.02919501
```

## B.2.4 Multiple Logistic Regression

```
full.mod = glm(default~., data=Default,family=binomial)
```

```
summary(full.mod)
```

```
##
## Call:
## glm(formula = default ~ ., family = binomial, data = Default)
##
## Deviance Residuals:
##      Min       1Q   Median       3Q      Max
## -2.4691  -0.1418  -0.0557  -0.0203   3.7383
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept) -1.087e+01  4.923e-01 -22.080  < 2e-16 ***
## studentYes   -6.468e-01  2.363e-01  -2.738  0.00619 **
## balance       5.737e-03  2.319e-04  24.738  < 2e-16 ***
## income        3.033e-06  8.203e-06   0.370  0.71152
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##      Null deviance: 2920.6  on 9999  degrees of freedom
## Residual deviance: 1571.5  on 9996  degrees of freedom
## AIC: 1579.5
##
## Number of Fisher Scoring iterations: 8
```

Perhatikan bahwa pola pengaruh peubah penjelas tidak sama seperti yang dihasilkan pada model sebelumnya yang hanya menggunakan satu peubah penjelas. Dimana sebelumnya `studentYes` bernilai positif.

## B.3 Model Evaluation

### B.3.1 Pseudo $R^2$

```
pscl::pR2(reglog)["McFadden"]
```

```
## fitting null model for pseudo-r2
```

```
## McFadden
## 0.4533916
```

```
pscl::pR2(reglog2)["McFadden"]
```

```
## fitting null model for pseudo-r2
```

```
##      McFadden  
## 0.004097255
```

```
pscl::pR2(full.mod)["McFadden"]
```

```
## fitting null model for pseudo-r2
```

```
##      McFadden  
## 0.4619194
```

## C. Lending Club Datasets

### C.1 Eksplorasi Data

Pada ilustrasi ini akan digunakan data Lending Club Data.

```
loan <- read_csv("https://www.dropbox.com/s/89g1yyhwpcqwjn9/lending_club_cleaned.csv?raw=1")
```

```
##  
## -- Column specification -----  
## cols(  
##   good = col_character(),  
##   purpose = col_character(),  
##   fico = col_double(),  
##   dti = col_double(),  
##   loan_amnt = col_double(),  
##   income = col_double()  
## )
```

- Peubah `good` merupakan indikator apakah pinjaman tersebut termasuk baik (good) atau buruk (bad);
- Peubah `fico` merupakan skor kredit dimana skor yang lebih tinggi adalah yang lebih baik;
- Peubah `dti` menunjukkan rasio debt-to-income,
- Peubah `loan_amnt` menunjukkan jumlah pinjaman dan
- Peubah `income` menunjukkan pendapatan. Sebagai catatan, peubah income bernilai NA jika sumber pendapatan tidak terverifikasi.

## Loan

```
## # A tibble: 42,535 x 6
##   good purpose      fico   dti loan_amnt income
##   <fct> <chr>      <dbl> <dbl>    <dbl> <dbl>
## 1 good  debt_consolidation  737 27.6     5000 24000
## 2 bad   major_purchase     742 1       2500 30000
## 3 good  small_business     737 8.72    2400  NA
## 4 good  other              692 20     10000 49200
## 5 good  other              697 17.9    3000 80000
## 6 good  vacation_wedding   732 11.2    5000 36000
## 7 good  debt_consolidation  692 23.5    7000  NA
## 8 good  major_purchase     662 5.35    3000 48000
## 9 bad   small_business     677 5.55    5600 40000
## 10 bad  other              727 18.1    5375 15000
## # ... with 42,525 more rows
```

```
summary(loan)
```

```
##      good      purpose      fico      dti
## Length:42535 Length:42535 Min.   :612.0 Min.   : 0.00
## Class :character Class :character 1st Qu.:687.0 1st Qu.: 8.20
## Mode  :character Mode  :character Median :712.0 Median :13.47
##                                     Mean  :715.1 Mean  :13.37
##                                     3rd Qu.:742.0 3rd Qu.:18.68
##                                     Max.   :827.0 Max.   :29.99
##
##      loan_amnt      income
## Min.   : 500 Min.   : 4800
## 1st Qu.: 5200 1st Qu.: 44995
## Median : 9700 Median : 63000
## Mean   :11090 Mean   : 75186
## 3rd Qu.:15000 3rd Qu.: 90000
## Max.   :35000 Max.   :6000000
##                                     NA's :18758
```

```
table(loan$good)
```

```
##
##   bad   good
## 6371 36164
```

```
loan$good<-as.factor(loan$good)
```

```
loan
```

```
## # A tibble: 42,535 x 6
##   good purpose      fico      dti loan_amnt income
##   <fct> <chr>      <dbl> <dbl>      <dbl> <dbl>
## 1 good debt_consolidation 737 27.6      5000 24000
## 2 bad  major_purchase    742 1          2500 30000
## 3 good small_business    737 8.72       2400  NA
## 4 good other          692 20        10000 49200
## 5 good other          697 17.9       3000 80000
## 6 good vacation_wedding 732 11.2       5000 36000
## 7 good debt_consolidation 692 23.5       7000  NA
## 8 good major_purchase    662 5.35       3000 48000
## 9 bad  small_business    677 5.55       5600 40000
## 10 bad other          727 18.1       5375 15000
## # ... with 42,525 more rows
```

## C.2 Membagi Data

Untuk kepentingan prediksi model, data akan dibagi dua menjadi data `train` dan data `test`. Karena pembagian data ini menggunakan sampling, maka perlu dilakukan pengaturan seed untuk randomisasi.

```
set.seed(5815)

sample <- sample(nrow(loan), floor(nrow(loan)*0.8))

train <- loan[sample,]

test <- loan[-sample,]
```

Sehingga, kita mempunyai dua data, `train` untuk membentuk model, dan `test` untuk menguji model yang telah dibuat.

## C.3 Model

Pada ilustrasi ini, peubah `fico`, `dti`, `loan_amnt`, dan `purpose` akan digunakan sebagai peubah penjelas

```
logit <- glm(good ~ fico + dti + loan_amnt + purpose, data = train, family = "binomial")

summary(logit)
```

```
##
## Call:
## glm(formula = good ~ fico + dti + loan_amnt + purpose, family = "binomial",
##      data = train)
##
## Deviance Residuals:
##      Min       1Q   Median       3Q      Max
## -2.7320    0.3863    0.5134    0.6182    1.2736
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)   -7.209e+00  3.483e-01 -20.701 < 2e-16 ***
## fico           1.336e-02  4.929e-04  27.098 < 2e-16 ***
## dti            -1.007e-02  2.420e-03  -4.161 3.17e-05 ***
## loan_amnt      -2.353e-05  2.131e-06 -11.042 < 2e-16 ***
## purposeeducational -5.343e-01  1.404e-01  -3.805 0.000142 ***
## purposehome_improvement -1.807e-01  5.879e-02  -3.075 0.002108 **
## purposemajor_purchase  5.330e-02  6.384e-02   0.835 0.403748
## purposemedical    -4.120e-01  1.116e-01  -3.693 0.000222 ***
## purposeother      -3.539e-01  4.797e-02  -7.377 1.62e-13 ***
## purposesmall_business -9.250e-01  6.222e-02 -14.867 < 2e-16 ***
## purposevacation_wedding  8.354e-02  9.607e-02   0.870 0.384502
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##      Null deviance: 28698  on 34027  degrees of freedom
## Residual deviance: 27547  on 34017  degrees of freedom
## AIC: 27569
##
## Number of Fisher Scoring iterations: 5
```

## C.4 Evaluasi Model

### C.4.1 Confusion Matrix

Sensitivitas (atau True Positive Rate) adalah persentase pengamatan (aktual) yang diprediksi dengan benar oleh model, sedangkan spesifisitas adalah persentase dari 0 (aktual) yang diprediksi dengan benar.

```
test$pred <- predict(logit, test, type="response")
```

```
test$good_pred <- ifelse(test$pred > 0.80, "good", "bad")
```

```
test$good_pred <- as.factor(test$good_pred)
```



```
(conf.mat<-caret::confusionMatrix(test$good_pred, test$good, positive="good"))
```

```
## Confusion Matrix and Statistics
##
##              Reference
## Prediction   bad good
##      bad    418 1272
##      good    869 5948
##
##              Accuracy : 0.7483
##              95% CI : (0.739, 0.7575)
##      No Information Rate : 0.8487
##      P-Value [Acc > NIR] : 1
##
##              Kappa : 0.1317
##
##  Mcnemar's Test P-Value : <2e-16
##
##      Sensitivity : 0.8238
##      Specificity : 0.3248
##      Pos Pred Value : 0.8725
##      Neg Pred Value : 0.2473
##      Prevalence : 0.8487
##      Detection Rate : 0.6992
##      Detection Prevalence : 0.8013
##      Balanced Accuracy : 0.5743
##
##      'Positive' Class : good
##
```

```
broom::tidy(conf.mat)
```

```
## # A tibble: 14 x 6
##   term                class estimate conf.low conf.high  p.value
##   <chr>              <chr>   <dbl>   <dbl>   <dbl>   <dbl>
## 1 accuracy          <NA>    0.748   0.739   0.758  1.00e+ 0
## 2 kappa             <NA>    0.132   NA      NA      NA
## 3 mcnemar           <NA>    NA      NA      NA      3.69e-18
## 4 sensitivity       good    0.824   NA      NA      NA
## 5 specificity       good    0.325   NA      NA      NA
## 6 pos_pred_value    good    0.873   NA      NA      NA
## 7 neg_pred_value    good    0.247   NA      NA      NA
## 8 precision         good    0.873   NA      NA      NA
## 9 recall            good    0.824   NA      NA      NA
## 10 f1               good    0.847   NA      NA      NA
## 11 prevalence       good    0.849   NA      NA      NA
## 12 detection_rate   good    0.699   NA      NA      NA
## 13 detection_prevalence good    0.801   NA      NA      NA
## 14 balanced_accuracy good    0.574   NA      NA      NA
```